Relatório Ciência de Dados 1ºFase

Francisco Palmeira 2109923
Universidade da Madeira
Engenharia Informática
Funchal, Portugal

Omar Jesus 2099223
Universidade da Madeira
Engenharia Informática
Funchal, Portugal

***Resumo*—Este documento apresenta as três primeiras fases do ciclo de vida de análise de dados aplicadas ao dataset "Flight Delay and Cancellation (2019-2023)". O objetivo principal é reformular a previsão de atrasos como um problema de classificação multiclasse (On-time, Short delay, Long delay). São detalhados os processos de limpeza de dados, Feature Engineering (criação de mais de 10 novas features), análise exploratória, testes de hipóteses estatísticas e a estratégia de seleção de modelos.**

***Index Terms*—Ciência de Dados, Aviação, Machine Learning, Feature Engineering, Testes de Hipóteses, Classificação.**

I. Introdução

A. Contextualização do Problema

A pontualidade é um dos indicadores de desempenho mais críticos na aviação comercial. Os atrasos geram custos operacionais elevados e insatisfação nos passageiros. Este projeto utiliza dados do Departamento de Transportes dos EUA para mitigar este problema através da previsão proativa de atrasos baseada em fatores operacionais e temporais.

B. Objetivos da Análise

O objetivo central deste trabalho é classificar o estado de chegada de um voo em três categorias distintas: *On-time* (atraso inferior a 15 minutos), *Short delay* (entre 15 e 30 minutos) e *Long delay* (superior a 30 minutos). Esta reformulação permite uma abordagem direcionada à operação das companhias aéreas.

II. Conjunto de Dados e Pré-processamento

A. Descrição do Dataset

O conjunto de dados original contém milhões de registos de voos comerciais operados por companhias dos EUA. Para otimização computacional e visualização, foi utilizada uma amostra representativa de dados.

B. Prevenção de Data Leakage

Garantir a ausência de *data leakage* foi uma prioridade crítica para assegurar a validade do modelo. Variáveis que contêm informação posterior à descolagem, ou que derivam diretamente da variável alvo, foram estritamente removidas. Foram eliminadas colunas como *DEP_DELAY*, *TAXI_OUT*, *WHEELS_OFF*, tempos de voo reais (*ACTUAL_ELAPSED_TIME*) e todas as variáveis de justificação de atraso (*DELAY_DUE_CARRIER*, etc.).

C. Limpeza e Tratamento de Dados

O processo de limpeza iniciou-se com a exclusão de voos cancelados ou divergidos, uma vez que não possuem valores quantificáveis de atraso à chegada. Foram removidas linhas duplicadas e registos com valores nulos (*NaN*). Para identificar e remover *outliers* nas variáveis numéricas contínuas, aplicou-se o método do *Z-score*.

De forma a cumprir os objetivos de negócio, e sabendo que prever chegadas antecipadas não acrescenta valor operacional, todos os atrasos negativos (voos adiantados) foram convertidos para zero. Adicionalmente, para mitigar o desequilíbrio de classes e otimizar o tempo de computação, realizou-se uma amostragem (*Undersampling*), garantindo que o conjunto de dados final contém uma proporção exata de 50% de voos com atraso e 50% de voos pontuais.

D. Feature Engineering

De forma a enriquecer a capacidade preditiva e captar padrões complexos, foram criadas mais de 10 novas variáveis a partir dos dados originais:

- **Temporais:** Mês (*MONTH*), Dia da Semana (*DAY_OF_WEEK*), Fim de Semana (*IS_WEEKEND*), Estação do Ano (*SEASON*), Mês de Férias (*IS_HOLIDAY_MONTH*), Hora Planeada de Partida e Chegada (*CRS_DEP_HOUR*, *CRS_ARR_HOUR*) e Período do Dia (*TIME_OF_DAY*).
- **Geográficas e Operacionais:** Rota que combina a origem e destino (*ROUTE*), Tipo de Voo categorizado por distância (*FLIGHT_TYPE*) e Velocidade Planeada (*PLANNED_SPEED*).
- **Target Encoding:** Foi criada a variável *AVG_DELAY_PER_HOUR*, que calcula a média histórica de atraso para cada hora do dia. Para evitar *data leakage*, este mapeamento foi ajustado exclusivamente no conjunto de treino e posteriormente aplicado ao conjunto de teste.

E. Normalização e Estandardização

Para preparar os dados para os algoritmos de *Machine Learning*, implementou-se um processo de transformação robusto. As variáveis categóricas em formato de texto (como os códigos dos aeroportos e das companhias aéreas) foram convertidas para valores numéricos utilizando a técnica *Label Encoding*.

Em seguida, aplicaram-se diferentes técnicas de escala consoante a natureza da variável: as variáveis puramente

numéricas e contínuas (como distância e tempos decorridos) foram estandardizadas utilizando o *StandardScaler* (média 0 e desvio padrão 1), enquanto as variáveis categóricas já codificadas numericamente foram normalizadas com o *MinMaxScaler*, garantindo que todas as matrizes de dados convergem de forma eficiente durante o treino.

III. Análise Exploratória de Dados (EDA)

A. Distribuições e Relações Bivariadas

O primeiro passo consistiu em analisar a distribuição das variáveis numéricas e a sua interação. Através da classe de visualização, gerámos *Pairplots* e histogramas para mapear a dispersão dos dados.

- Observámos que variáveis contínuas, como o tempo de voo planeado (`CRS_ELAPSED_TIME`) ou a distância (`DISTANCE`), apresentam distribuições com assimetrias e uma vasta gama de valores, reforçando a necessidade do pré-processamento (como o *Scaling* que aplicámos posteriormente).
- Para analisar os atrasos em função das nossas categorias criadas (como a Estação do Ano ou Altura do Dia), utilizámos gráficos de densidade (*Ridgeplots*) e *Boxplots*. Estes gráficos confirmaram visualmente o que os testes de hipóteses provaram matematicamente: o perfil da cauda de atrasos (a frequência de voos com atrasos extremos) alarga-se significativamente em categorias específicas, como nos meses de férias ou nos voos noturnos.

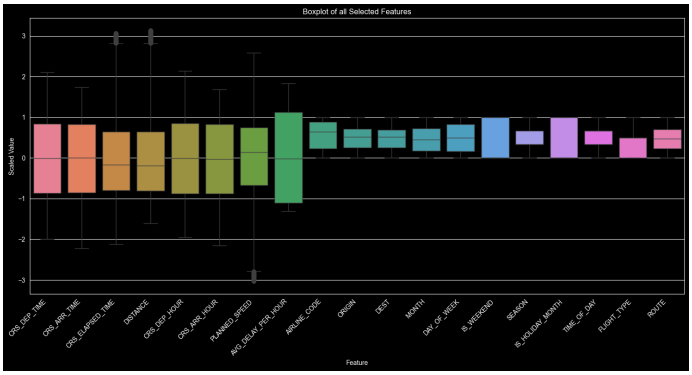

Figura 1. Distribuição de atrasos e relações bivariadas (BoxPlots).

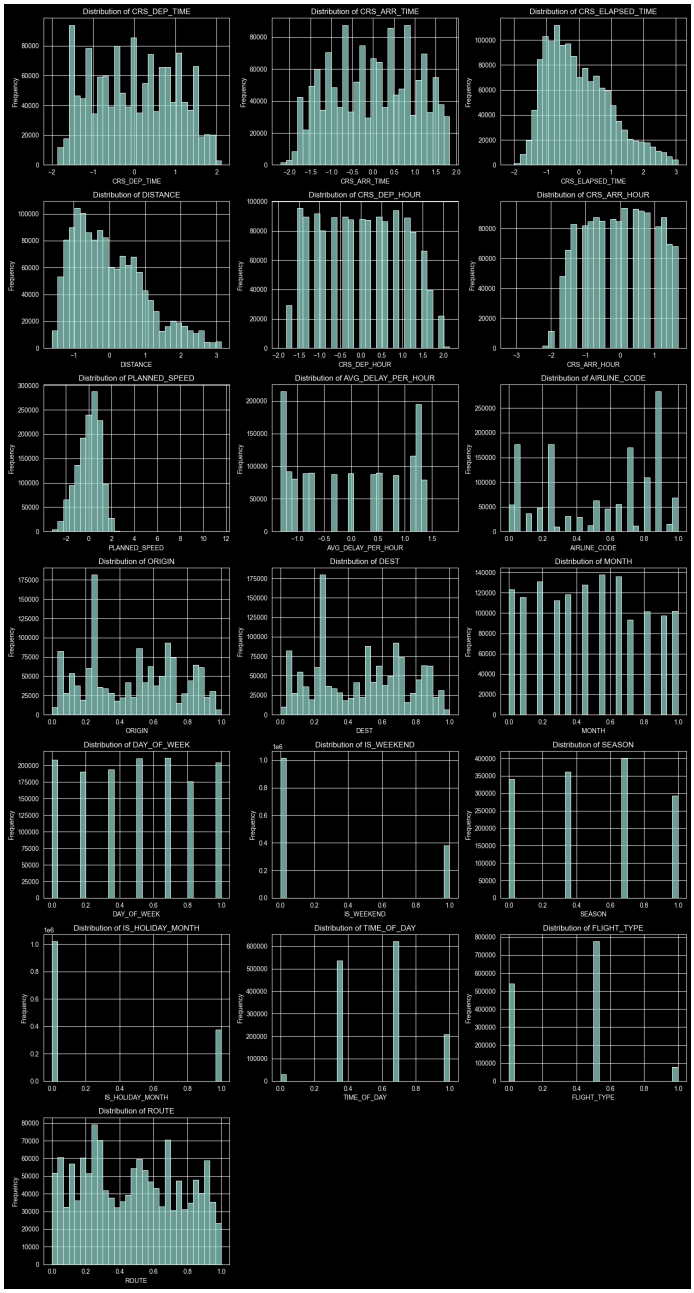

Figura 2. Distribuição de atrasos e relações bivariadas (PairPlots).

B. Análise de Correlação Linear (Heatmap)

Para testar a força das relações lineares diretas entre as variáveis numéricas originais e o atraso na chegada (`ARR_DELAY`), construímos uma Matriz de Correlação de Pearson, visualizada através de um *Heatmap*. Os resultados do *Heatmap* revelaram coeficientes de correlação linear muito baixos (próximos de 0) entre as variáveis numéricas contínuas e a variável alvo. Esta observação é de extrema importância para o projeto, pois atua como a segunda prova matemática de que **não existe uma relação linear simples que explique os atrasos dos voos**. O atraso não aumenta proporcionalmente com a distância ou com a hora exata de partida de forma

isolada; ele é o resultado de uma combinação complexa de fatores contextuais (como um voo longo, num dia de chuva, em época de férias). Os resultados deste processo foram incrivelmente reveladores:

1) As nossas *features* categóricas criadas na fase de *Feature Engineering* (como `TIME_OF_DAY`, `FLIGHT_TYPE` e `SEASON`) dominaram o topo do gráfico de importância. O modelo baseou fortemente as suas decisões nestas variáveis.
2) O algoritmo provou que a contextualização do voo (saber se é um voo matinal ou se ocorre num mês de férias) tem um poder preditivo muito superior do que apenas fornecer ao modelo o minuto exato da partida ou a milha exata de distância.

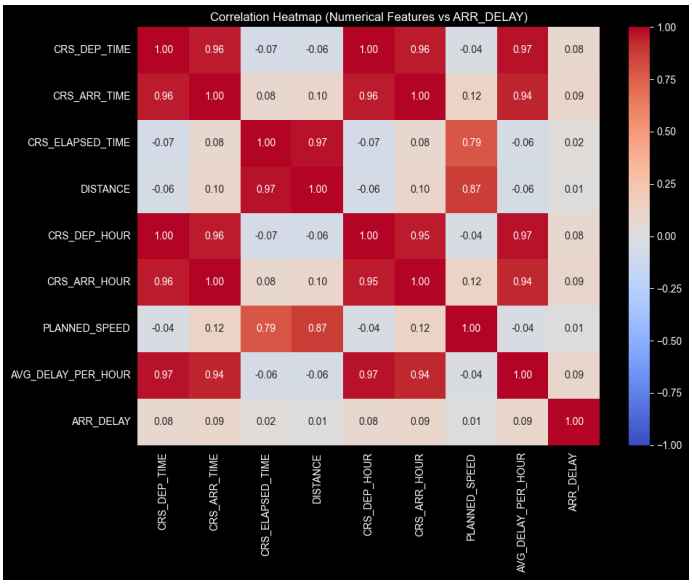

Figura 3. Matriz de Correlação (Heatmap) entre variáveis numéricas e o atraso na chegada.

C. Importância das Variáveis (Feature Importance)

Como a correlação linear se revelou insuficiente, recorremos a um método muito mais robusto e não-linear para avaliar o verdadeiro valor preditivo das nossas *features*: a Importância por Permutação (*Permutation Importance*).

Para tal, treinámos um modelo base de *Random Forest Regressor* numa amostra representativa dos dados e avaliámos o impacto que a aleatorização (*shuffling*) de cada coluna tem no erro do modelo.

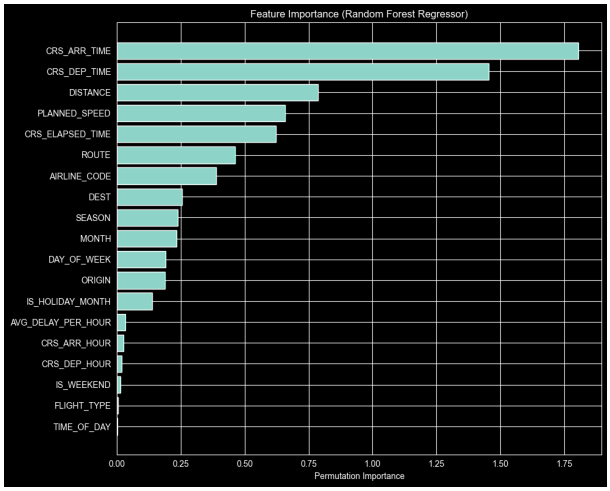

Figura 4. Importância das Variáveis (Permutation Importance) utilizando um Random Forest Regressor base.

D. Redução de Dimensionalidade: Análise Linear e não linear de Clusters.

Para identificar padrões globais, aplicou-se um método linear (PCA) e métodos não-lineares (UMAP e t-SNE). Estas técnicas permitiram comprimir a elevada dimensionalidade do dataset e visualizar o agrupamento dos voos de acordo com características geográficas ou temporais. Começámos por aplicar o algoritmo PCA para tentar resumir o conjunto de dados procurando combinações lineares das nossas features que capturassem a maior variância possível. No entanto, a projeção 2D resultante do PCA mostrou-se ineficaz a separar os voos de forma clara, resultando numa nuvem de pontos densa e sobreposta (um aglomerado contínuo). Este resultado foi crucial, pois provou matematicamente que a estrutura do nosso problema é complexa; as variáveis originais (como distância exata ou tempo de voo) não se relacionam com os atrasos através de simples linhas retas matemáticas.

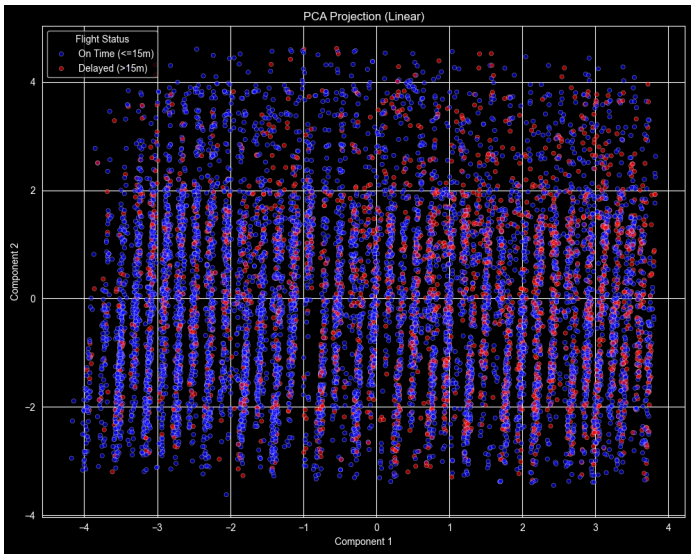

Figura 5. Principal Component Analysis (PCA).

Para além do PCA, e de forma a capturar as relações complexas e não-lineares, aplicámos primeiramente o algoritmo t-SNE (*t-Distributed Stochastic Neighbor Embedding*). Devido à sua elevada complexidade computacional para grandes volumes de dados ($O(N^2)$), o t-SNE foi aplicado a uma sub-amostra rigorosa e controlada do *dataset*. A projeção bidimensional gerada pelo t-SNE começou a revelar a verdadeira natureza dos dados, agrupando os voos em *clusters* fragmentados com base nas *features* operacionais e temporais criadas. Embora o t-SNE seja excelente a preservar a estrutura local (garantindo que voos semelhantes ficam próximos), ele tende a perder a noção da estrutura global (a distância real entre *clusters* diferentes).

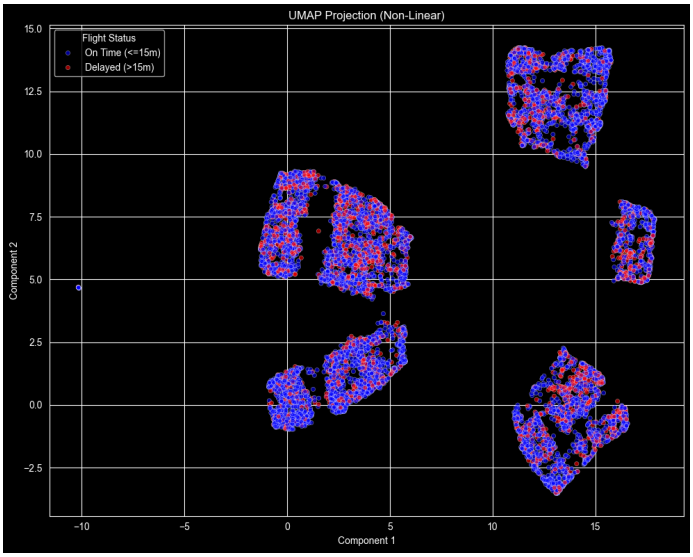

Figura 7. Uniform Manifold Approximation and Projection(UMAP)

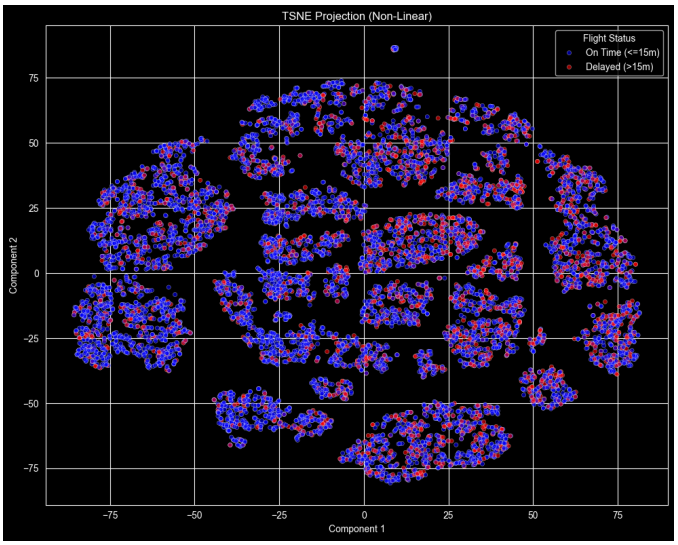

Figura 6. Projeção não-linear utilizando o algoritmo t-SNE.

Perante a ineficácia da abordagem linear(PCA) e a não-linear(t-SNE), aplicámos o UMAP (Uniform Manifold Approximation and Projection), um algoritmo capaz de compreender estruturas não-lineares complexas. A projeção das nossas features categóricas recém-criadas no espaço UMAP revelou agrupamentos altamente distintos e perfeitamente separados.

Para analisar os fatores determinantes por trás destes clusters, colorimos as projeções UMAP utilizando a paleta científica padrão viridis. Este gradiente mapeia as categorias numéricas do valor mais baixo para o mais alto sendo Roxo Escuro(Representa o valor numérico mais baixo numa categoria ex.: 0 / Curto Curso), Verde Claro(Representa os valores intermédios ex.: 1 / Médio Curso). Amarelo: Representa o valor numérico mais alto numa categoria ex.: 2 / Longo Curso).

- **Espaço entre os Clusters:** A Feature (*FLIGHT_tYPE*) é o principal fator que cria os enormes espaços entre clusters distintos. O algoritmo identificou que os voos de Curto, Médio e Longo Curso representam perfis operacionais fundamentalmente diferentes e agrupou-os em ”ilhas”completamente isoladas.
- **Os Clusters:** Variáveis como (*IS_HOLIDAY_MONTH*) dividem ainda mais estes grupos principais. Observámos sub-clusters distintas que são completamente azuis (Não-Férias) versus completamente verdes (Férias), provando que a época do ano altera drasticamente o comportamento estrutural de um voo.
- **Camadas entre os Clusters:** Variáveis como (*TIME_OF_DAY*) organizam os dados dentro dos clusters individuais. Em vez de pintar uma ilha inteira de uma cor sólida, a altura do dia cria um gradiente distinto (Roxo na base, Verde Água no meio, Amarelo no topo). Isto indica que, dentro de uma macro-categoria específica, o algoritmo agrupa com sucesso e de forma local os voos da Manhã, Tarde e Noite.

O contraste direto entre a falha do PCA e o sucesso do UMAP valida matematicamente a nossa fase de Feature Engineering. Prova que o conjunto de dados é altamente estruturado, mas estritamente não-linear. Desta forma, fica justificado que a utilização de modelos de Regressão Linear tradicionais falharia neste projeto.

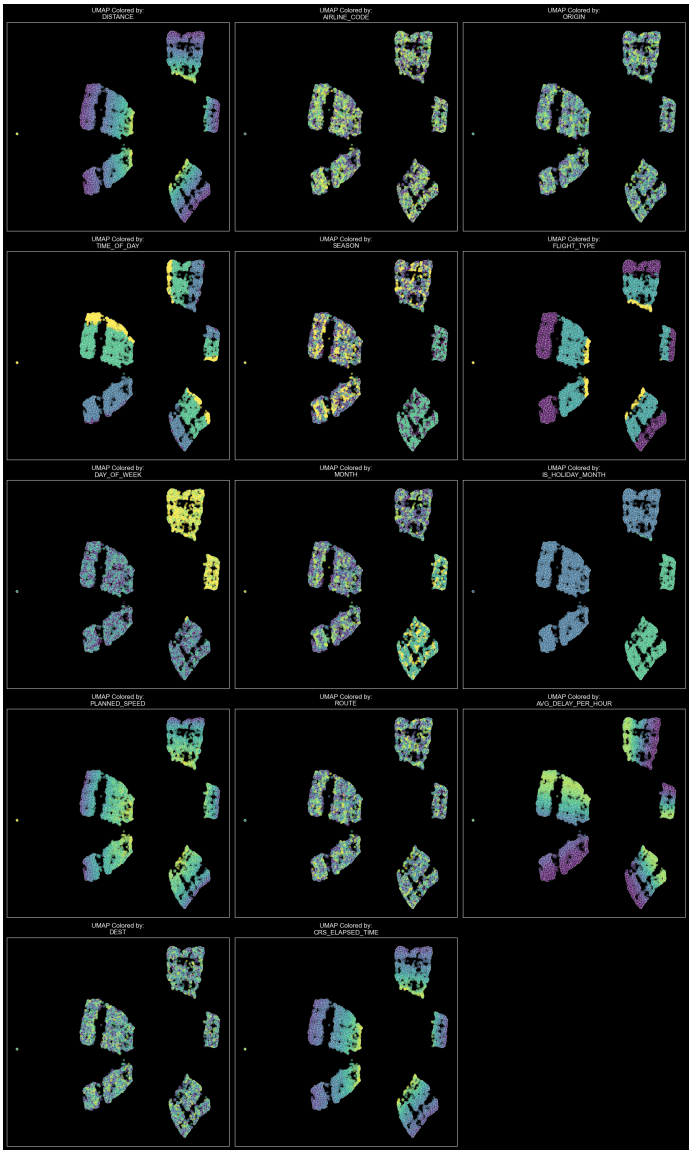

Figura 8. Distribuição do UMAP feita por 14 features distintas)

IV. Testes de Hipóteses

A. Formulação e Metodologia

Para validar estatisticamente a fase de *Feature Engineering*, procurou-se provar a relação entre as novas variáveis criadas e a variável alvo contínua (*ARR_DELAY*). Definiu-se um nível de significância padrão de $\alpha = 0.05$.

A escolha dos testes estatísticos foi rigorosamente adaptada à natureza empírica dos dados. A variável alvo apresenta uma distribuição fortemente enviesada à direita (*Right-Skewed Distribution*), com a maioria dos voos concentrados perto do zero e uma longa cauda de *outliers* correspondentes a atrasos severos. Por esta razão, a Análise de Variância (ANOVA) foi descartada, pois a premissa de normalidade não é cumprida, o que originaria resultados pouco fiáveis. Em alternativa, aplicou-se a seguinte metodologia:

- **Teste T de Welch:** Utilizado para variáveis binárias (ex: *IS_WEEKEND*, *IS_HOLIDAY_MONTH*), comparando a média de atrasos entre dois grupos independentes.
- **Teste de Kruskal-Wallis:** Uma alternativa não-paramétrica à ANOVA, aplicada para testar variáveis multiclasse (ex: *TIME_OF_DAY*, *SEASON*, *FLIGHT_TYPE*).

B. Resultados (Variáveis Categóricas)

Os testes estatísticos revelaram que todas as variáveis categóricas alvo de engenharia possuem uma relação estatisticamente significativa com os atrasos à chegada (*ARR_DELAY*), retornando valores de p drasticamente inferiores ao limiar de significância de $\alpha = 0.05$.

Nos testes T de Welch aplicados a variáveis binárias, verificou-se que tanto a ocorrência de fim de semana (*IS_WEEKEND*, $p \approx 1.35 \times 10^{-15}$) como a altura de férias (*IS_HOLIDAY_MONTH*, $p \approx 7.38 \times 10^{-305}$) afetam de forma significativa os tempos de voo. Adicionalmente, os testes não-paramétricos de Kruskal-Wallis realizados para as variáveis multiclasse (*TIME_OF_DAY*, *SEASON*, *FLIGHT_TYPE*, *DAY_OF_WEEK* e *MONTH*) apresentaram valores de p virtualmente iguais a zero ($p < 0.0001$).

Deste modo, rejeita-se firmemente a hipótese nula para a totalidade das *features* em análise. Fica assim provado, de forma rigorosa, que estas variáveis operacionais e temporais não são mero ruído, fornecendo um sinal válido e estatisticamente robusto para a fase de modelação preditiva.

C. Validação de Variáveis Numéricas (Pearson)

Uma vez que os testes anteriores são exclusivos para variáveis categóricas, a validação estatística das novas variáveis numéricas contínuas foi realizada através da correlação de Pearson.

A análise revelou que a técnica de *Target Encoding* foi bem-sucedida, com a variável *AVG_DELAY_PER_HOUR* a apresentar a correlação mais forte com a variável alvo ($r = 0.09$). Por outro lado, variáveis operacionais como a Distância (*DISTANCE*) e a Velocidade Planeada (*PLANNED_SPEED*) demonstraram correlações residuais idênticas ($r = 0.01$). Estes valores comprovam de forma clara que não existe uma relação linear simples capaz de explicar os atrasos na aviação, justificando plenamente a necessidade de recorrer a algoritmos não-lineares e baseados em árvores (como *Random Forests*) nas fases seguintes do projeto.

V. Seleção de Modelos e Metodologia

A. Abordagem de Modelação

Com a conclusão da preparação de dados e validação estatística, o problema de negócio transita para a fase de modelação preditiva (Fase 3). O objetivo central consiste numa tarefa de classificação multiclasse, onde cada voo será categorizado em três níveis de estado à chegada: *On-time* (atrasos inferiores a 15 minutos), *Short delay* (atrasos de 15 a 30 minutos) e *Long delay* (atrasos superiores a 30 minutos).

B. Algoritmos Selecionados

Para capturar os padrões complexos inerentes aos dados de aviação comercial, foram selecionados os seguintes algoritmos de *Machine Learning*:

- **K-Nearest Neighbors (KNN):** Um algoritmo baseado em distância que será implementado de raiz (*from scratch*) para este projeto. Servirá como modelo de *baseline*, tirando partido do espaço multidimensional criado durante a fase de estandardização.
- **Modelos Baseados em Árvores (*Decision Trees* e *Random Forests*):** Como demonstrado previamente pelas baixas correlações lineares das variáveis contínuas, a relação entre as *features* e os atrasos é estritamente não-linear. O algoritmo *Random Forest* é ideal para este cenário, lidando de forma excecional com variáveis categóricas, relações não-lineares e interações complexas entre atributos operacionais e temporais.

C. Metodologia de Treino e Avaliação

A avaliação rigorosa dos modelos é crucial para garantir a sua aplicabilidade no mundo real e a sua capacidade de generalização para novos dados. A metodologia planeada inclui:

- **Divisão dos Dados:** O conjunto de dados, previamente equilibrado através da técnica de *Undersampling*, foi dividido de forma estratificada num subconjunto de treino (80%) e teste (20%).
- **Validação Cruzada (*Cross-Validation*):** Será aplicada no conjunto de treino para otimizar iterativamente os hiperparâmetros (como o valor de K no KNN ou o número de estimadores nas *Random Forests*), mitigando ativamente o risco de sobreajuste (*overfitting*).
- **Métricas de Desempenho:** A avaliação não dependerá exclusivamente da Exatidão (*Accuracy*). Serão privilegiadas métricas robustas para classificação multiclasse, como a Precisão, a Sensibilidade (*Recall*) e o *F1-Score*. A Matriz de Confusão será o instrumento analítico principal para quantificar a taxa de falsos positivos e falsos negativos entre as diferentes severidades de atraso.

VI. Conclusão Preliminar

O desenvolvimento destas três primeiras fases do ciclo de vida dos dados estabeleceu uma fundação analítica excecionalmente robusta para o problema de previsão de atrasos na aviação comercial. O tratamento minucioso do conjunto de dados garantiu a mitigação total de *data leakage*, enquanto a aplicação de técnicas de *Undersampling* resolveu eficazmente o desequilíbrio de classes nativo deste domínio.

A fase de *Feature Engineering* provou ser o pilar central deste progresso. A criação de variáveis temporais e operacionais — com particular destaque para a técnica de *Target Encoding* na média horária de atrasos — revelou-se altamente eficaz. Esta eficácia não foi apenas observada na separação visual dos agrupamentos através das técnicas de redução de dimensionalidade (UMAP e PCA), mas foi também provada de forma inegável e rigorosa através dos testes de hipóteses estatísticas, onde todas as variáveis propostas demonstraram significância máxima ($p < 0.0001$).

Com os dados limpos, transformados, validados matematicamente e a estratégia de validação cruzada delineada, o projeto encontra-se em perfeitas condições para avançar para a fase de Modelação. A equipa está agora preparada para implementar o algoritmo K-Nearest Neighbors de raiz e treinar modelos baseados em árvores, com a confiança estatística de que o modelo aprenderá a partir de um sinal limpo e representativo da realidade operacional das companhias aéreas.

Referências

[1] Departamento de Transportes dos EUA, "Flight Delay and Cancellation Dataset (2019-2023)," Kaggle. [Online]. Disponível: https://www.kaggle.com/datasets/patrickzel/flight-delay-and-cancellation-dataset-2019-2023/data